

ASTRA: High Throughput 3PC over Rings with Application to Secure Prediction

论文下载[链接](#)

0. ABSTRACT

本文提出一种考虑半诚实和恶意安全性的三方计算协议，采用offline-online的范式，能够抵抗1方静态敌手攻击。半诚实安全假设下，在环 \mathbb{Z}_{2^ℓ} 中，一个乘法门的在线计算阶段仅需总通信2 ring elements，这在3PC设定中是首次实现的。在恶意安全假设下，乘法计算需要4 ring elements的总通信量，通信效率高于ABY3的5 ring elements。与此同时，恶意安全设定下也实现了Fairness（恶意方接收到output，诚实方必须获得output），且不附带多余的通信量。

作者将安全3PC协议应用到ML安全预测任务上（linear regression, linear SVM regression, logistic regression, and linear SVM classification）。将计算外包给三台不合谋的服务器，其构造满足半诚实和恶意安全的设定，其性能表现是当前最优。

1. INTRODUCTION

安全3PC计算在半诚实和恶意设定下得到了相当有关关注，本文主要的目标是提升效率。基于SS的方法可以在linear门实现非交互，所以重点关注multiplication门的算法设计。一个提升效率的方向是采用offline-online两阶段的方法，offline阶段执行与input无关的操作，online阶段执行与input有关的且快速的操作。现有的3PC计算协议可以分为两类：1) 支持在素域下的算术计算；2) 支持半诚实下环上的算术电路计算。现有的方案各有优缺点。

Our Contribution

本文所提出的协议都拥有一个的特点是在线计算的通信比3 pair少，因此也产生了更好的在线计算性能。将贡献总结如下：

1. Secure 3PC：我们的协议在半诚实安全设定下，计算乘法时在线计算阶段通信仅需要2 elements。平均下来每方的通信量小于1 elements，这在3PC下是第一次做到的。对于恶意安全的设定下，我们的乘法计算在线阶段通信需要4 elements，是现在最好的通信效率。此外，恶意安全下也满足Fairness。
2. Secure ML prediction：我们考虑MLaaS的场景，使用辅助服务器完成ML的安全预测。我们与ABY³的效率进行了比较，并提出一种新颖的应用在分类协议中的常数轮安全比较协议。
3. Implementation：对于3PC，协议基于 \mathbb{Z}_{2^ℓ} 环实现。我们使用延迟（runtime）和在线阶段的throughput作为性能比较的benchmarks。实验表明，我们的方法效率更高。

Shared Key Setup：使用预分享随机key的方式用RPF实现3PC非交互的通信。这里的keys有

1. 每对Parties有一个公共的key。 k_{01}, k_{02}, k_{12} 分别表示 $(P_0, P_1), (P_0, P_2), (P_1, P_2)$ 之间共有的key
2. 三方公有的两个key。 $k_{P,1}, k_{P,2}$

2. SHARING SEMANTICS

定义本文使用的三种类型的秘密分享形式：

1. $[\cdot]$ -sharing: 将 v 以加法秘密分享的形式分发给 P_1 和 P_2 , 满足 $v = v_1 + v_2$
2. $[\![\cdot]\!]$ -sharing: 一个值 v 被称为 $[\![\cdot]\!]$ -sharing 在 P_0, P_1, P_2 之间, 那么满足
 - 存在一个 λ_v, m_v 满足 $v = m_v - \lambda_v$
 - P_1, P_2 以明文的形式知道 m_v , λ_v 以 $[\cdot]$ -sharing 的形式分享在它们之间。即 $[\lambda_v]_{P_1} = \lambda_{v,1}, [\lambda_v]_{P_2} = \lambda_{v,2}$
 - P_0 以明文的方式知道 $\lambda_{v,1}, \lambda_{v,2}$
 我们将每一方的sharing表示为 $[\![v]\!]_{P_0} = (\lambda_{v,1}, \lambda_{v,2}), [\![v]\!]_{P_1} = (m_v, \lambda_{v,1}), [\![v]\!]_{P_2} = (m_v, \lambda_{v,2})$ 。
 将 v 的 $[\![\cdot]\!]$ -sharing 表示为 $[\![v]\!] = (m_v, [\lambda])$ 。
3. Linearity of the secret sharing scheme:
 - 给定 $x, y \in \mathbb{Z}_{2^l}$ 的 $[\cdot]$ -sharing, 以及常数 $c_1, c_2 \in \mathbb{Z}_{2^l}$, 参与方本地计算 $[c_1x + c_2y]$

$$\begin{aligned} [c_1x + c_2y] &= (c_1x_1 + c_2y_1, c_1x_2 + c_2y_2) \\ &= c_1[x] + c_2[y] \end{aligned}$$

- 同理, 给定 $x, y \in \mathbb{Z}_{2^l}$ 的 $[\![\cdot]\!]$ -sharing, 以及常数 $c_1, c_2 \in \mathbb{Z}_{2^l}$, 参与方本地计算 $[\![c_1x + c_2y]\!]$

$$\begin{aligned} [\![c_1x + c_2y]\!] &= (c_1m_x + c_2m_y, c_1[\lambda_x] + c_2[\lambda_y]) \\ &= c_1[\![x]\!] + c_2[\![y]\!] \end{aligned}$$

这种线性性质可以使得参与方本地计算加法和明文-密文乘法。

3. OUR 3PC PROTOCOL

3.1 3PC with semi-honest security

半诚实下的协议分为三个阶段-input-sharing, circuit-evaluation和output-reconstruction。

Input-sharing

协议 $\Pi_{\text{Sh}}^s(P_i, x)$ 使得指定方将 x 按 $[\![\cdot]\!]$ -sharing。比如 $P_i, i \in 1, 2$ 需要分享自己的输入 x 。离线阶段, P_0, P_i 随机采样得到 $\lambda_{x,i}$, 所有方随机采样得到 $\lambda_{x,3-i}$ 。这里 P_0, P_i 是可以得到 $\lambda_x = \lambda_{x,i} + \lambda_{x,3-i}$ 的; 在线阶段, P_i 发送 $m_x = x + \lambda_x$ 给 $P_j, j \in 1, 2$, 然后 P_j 令 $[\![x]\!]_{P_j} = (m_x, \lambda_{x,j})$ 。可以看到 P_i 没有泄露自己的隐私输入。

Circuit-evaluation

参与方按照电路拓扑顺序依次计算，对于加法门 $g : (w_x, w_y, w_z)$ ，那么可以按照Linearity of the secret sharing scheme本地计算，见协议 $\Pi_{\text{Add}}(w_x, w_y, w_z)$

对于乘法门 $g : (w_x, w_y, w_z)$ ，使用乘法协议 $\Pi_{\text{Mul}}^s(w_x, w_y, w_z)$ 计算 $\llbracket x \rrbracket \times \llbracket y \rrbracket = \llbracket z \rrbracket$ 。基本思想与ABY2.0相同，不同的是这是三方的设置。

Correctness: 令 $(m_x = x + \lambda_x), (m_y = y + \lambda_y)$ ，有 $\gamma_{xy} = \lambda_x \lambda_y$ 证明 $\Pi_{\text{Mul}}^s(w_x, w_y, w_z)$ 是正确的。

$$\begin{aligned} m_z &= m_x m_y - m_x \lambda_y - m_y \lambda_x + \lambda_z + \gamma_{xy} \\ &= (m_x - \lambda_x)(m_y - \lambda_y) + \lambda_z \\ &= xy + \lambda_z \end{aligned}$$

Output-reconstruction

重构比较简单，可以看到，每两方就可以还原输出 $y = m_y - \lambda_{y,1} - \lambda_{y,2}$ ，将重构协议命名为 Π_{Res}^s 。

最后将前面三个阶段的协议整合起来，命令为 $\Pi_{3\text{pc}}^s$

3.2 3PC with malicious security

3PC恶意安全的方案跟半诚实的方案类似，分为三个阶段。

Input Sharing and Output Reconstruction Stages:

在协议 Π_{Sh}^s 中 λ -shares 是consistent的，因为采样的时候非交互。但是，如果 P_0 拥有一个数 x 并且想创建一个inconsistent的 $\llbracket \cdot \rrbracket$ -sharing，那么它会发送不一致的 m_x 给 P_1, P_2 ，我们只需要让 P_1, P_2 交换验证 $H(m_x)$ 即可，如果不匹配则输出Abort。记Input Sharing为 Π_{Sh}^m 。

对于输出也是同样采用验证的方式，不匹配则输出Abort。记Reconstruction为 $\Pi_{\text{Rec}}^m(\llbracket y \rrbracket, P)$

Circuit Evaluation Stage:

Π_{Add} 是本地计算所以恶意者存在的情况下是不受影响的，所以重点考虑 Π_{Mul}^s 遭遇一个恶意者存在的情况。此时面临着两个问题：1) P_0 作为恶意者可以分享不正确的 $\gamma_{xy} \neq \lambda_x \lambda_y$ ；2) corrupt evaluator (P_1 or P_2) 可以在恢复 m_z 阶段作恶，发送不一致的 m_z ，所以讨论 Π_{Mul}^s 的恶意安全性需要分为 $\{P_0\}$ 和 $\{P_1, P_2\}$ 两个集合来讨论，但我们的方法可以将两种情况统一起来解决。主要的思想是：检查三元组的 $\llbracket \cdot \rrbracket$ -sharing的product-relation。具体地，

假设 P_1 的 m_z 被不正确的构造，需要检查它的正确性，可以借助 P_0 ： P_1 可以将 m_x, m_y 发送给 P_0 ，因为 P_0 在离线阶段知道 $\lambda_x, \lambda_y, \lambda_z$ ，所以它能计算出 m_z 并发送给 P_1 进行校验，但这样会泄露 m_x, m_y 明

文给 P_0 。于是考虑加一个掩码 $m_x^* = m_x + \delta_x, m_y^* = m_y + \delta_y$ 。 P_0 计算

$$\begin{aligned} m_z^* &= -m_x^* \lambda_y - m_y^* \lambda_x + \lambda_z + 2\gamma_{xy} \\ &= -(m_x + \delta_x) \lambda_y - (m_y + \delta_y) \lambda_x + \lambda_z + 2\gamma_{xy} \\ &= (m_z - m_x m_y) - (\delta_x \lambda_y + \delta_y \lambda_x - \gamma_{xy}) \\ &= (m_z - m_x m_y) - \chi \end{aligned}$$

这里把 $m_z = m_x m_y - m_x \lambda_y - m_y \lambda_x + \lambda_z + \gamma_{xy}$ 代入即可得到这个结论。如果 P_0 知道 χ 那么就可以计算 m_z^* 发送给 P_1, P_2 进行判断了。下面继续推导如果使 P_0 得到 χ 。我们发现如果向 P_0 公开 χ ，那么 P_0 根据自己拥有的 $\lambda_x, \lambda_y, \gamma_{xy}$ ，以及 $m_x + \delta_x, m_y + \delta_y$ 可以得到 $\lambda_y m_x + \lambda_x m_y$ 。所以我们要对 χ 加一个掩码，即 $\delta_x \lambda_y + \delta_y \lambda_x + \delta_z - \gamma_{xy}$ ，这里 δ_z 是一个随机数。所以可以让 P_1, P_2 随机采样 $\delta_x, \delta_y, \delta_z$ 然后做 χ 的 $[\cdot]$ -sharing并发送给 P_0 ， P_0 收到后做个Add就可以得到 χ 。这里引入了一个新的问题，如果 P_1, P_2 中的一个恶意者，那么要保证发送正确的 χ 的share。

梳理一下，通过前面的描述明晰了当evaluator中的一个恶意者的情况——检测不一致 m_z 的问题。并遗留下来两个问题：1) 当 P_0 作恶时， $\gamma_{xy} \neq \lambda_x \lambda_y$ ；2) 当 P_1 或者 P_2 作恶时，对 χ 的不正确发送。这两个问题通过离线阶段的三元组来解决。一旦 P_0 接收到 χ 后，各方本地计算 $a = \delta_x - \lambda_x, b = \delta_y - \lambda_y$ 以及 $c = (\delta_z + \delta_x \delta_y) - \chi$ 的 $[\cdot]$ -sharing。

观察到 (a, b, c) 构成一个乘法三元组

$$\begin{aligned} ab &= (\delta_x - \lambda_x)(\delta_y - \lambda_y) = \delta_x \delta_y + \lambda_x \lambda_y - \delta_x \lambda_y - \delta_y \lambda_x \\ &= (\delta_x \delta_y + \delta_z) - (\delta_x \lambda_y + \delta_y \lambda_x + \delta_z - \gamma_{xy}) \\ &= (\delta_z + \delta_x \delta_y) - \chi = c \end{aligned}$$

这里 $\gamma_{xy} = \lambda_x \lambda_y$ 。通过验证这个乘法元组（它的检验方法同《High-Throughput Secure Three-Party Computation for Malicious Adversaries and an Honest Majority》(EUROCRYPT'17)) 可以解决提到的这两个遗留问题：

(1) 如果 P_0 作恶， $\gamma_{xy} \neq \lambda_x \lambda_y$ ，不妨令 $\gamma_{xy} = \lambda_x \lambda_y + \Delta$ ，那么

$$\begin{aligned} c &= (\delta_x \delta_y + \delta_z) - (\delta_x \lambda_y + \delta_y \lambda_x + \delta_z - (\gamma_{xy} - \Delta)) \\ &= (\delta_x - \lambda_x)(\delta_y - \lambda_y) - \Delta = ab - \Delta \neq ab \end{aligned}$$

(2) 考虑evaluator中的一个作恶，不妨假设是 P_1 作恶。在发送 χ_1 给 P_0 的时候发送一个错误值 $\chi_1 + \Delta$ ，那么 P_0 恢复的值为 $\chi' = \chi + \Delta$

$$\begin{aligned}
c &= (\delta_x \delta_y + \delta_z) - \chi' = (\delta_x \delta_y + \delta_z) - (\chi + \Delta) \\
&= (\delta_x \delta_y + \delta_z) - (\delta_x \lambda_y + \delta_y \lambda_x + \delta_z - \gamma_{xy}) - \Delta \\
&= (\delta_x - \lambda_x)(\delta_y - \lambda_y) - \Delta = ab - \Delta \neq ab
\end{aligned}$$

(3) 加上前面讨论的一个问题：在线阶段 m_z 不一致，不妨假设 P_1 发送的 $[m_z]_{P_1} + \Delta$ 给 P_2 。那么诚实方 P_2 计算得到的是 $m_z + \Delta$ 。这种情况下，诚实方 P_0 在离线阶段正确计算了 $\chi = \delta_x \lambda_y + \delta_y \lambda_x + \delta_z - \gamma_{xy}$ 。由于在线计算阶段 P_0 得到了诚实的 $m_x + \delta_x, m_y + \delta_y$ 以及有 $\gamma_{xy} = \lambda_x \lambda_y$ 成立。如果它把这个结果发送给 P_1, P_2 ，那么 P_2 接收到的 m_z^* 与 $m_z + \Delta - m_x m_y + \delta_z$ 不同，所以会输出Abort。

下面是完整的恶意安全下的乘法计算协议

3.3 Achieving Fairness

我们通过一个公平的Reconstruct协议将 Π_{3pc}^m 的安全性从可中止提升到Fairness。为了fairly reconstruct $\llbracket y \rrbracket$ ，可以使用commitment。在离线阶段， $\{P_0, P_1\}$ 承诺它们的公共share $\lambda_{y,1}$ 发送给 P_2 ； $\{P_0, P_2\}$ 同样承诺公共的share $\lambda_{y,2}$ 发送给 P_1 ；在线阶段 $\{P_1, P_2\}$ 承诺它们的公共值 m_y 发送给 P_0 。由诚实大多数的假设下， $(P_0, P_1), (P_0, P_2), (P_1, P_2)$ 中至少有1对是诚实的。当承诺不匹配的时候，向其它方广播Abort。如果没有Abort的信号出现，则按照Reconstruct的规则打开 y 。但是这里会有一个问题，我们缺乏一个可信任的广播信道（有可能恶意方 P_0 向 P_1 发送Abort，向 P_2 发送continue的信号，最终结果就会出现不一致）。为解决这个问题，可以在离线阶段 $(P_0, P_1), (P_0, P_2)$ 分别将相应的随机数 r_1, r_2 的承诺 ($com(r_1), com(r_2)$) 发送给 P_2 和 P_1 。在线阶段 P_0 产生continue信号的时候则只发送continue；如果 P_0 发送abort，会附带关于 $com(r_{3-i})$ 的open信息 o_{3-i} 给 P_i ，这个 o_{3-i} 被 P_i 用来向 P_{3-i} 证明abort确实来做 P_0 而非 P_i 自己产生（因为 o_{3-i} 只有 P_0 和 P_{3-i} 持有）。

4. PRIVACY PRESERVING MACHINE LEARNING

使用前面的三方协议完成隐私保护ML预测任务（外包MPC的方式，三台不合谋的服务器）

4.1 Protocols for ML

(1) **Dot Product**：给定 d 维向量 \vec{p}, \vec{q} ， Π_{dp} 的目标是计算 $\vec{p} \odot \vec{q}$ 的 $\llbracket \cdot \rrbracket$ -sharing。如果直接使用 Π_{Mul} ，那么它的通信复杂度与 d 线性相关。半诚实下，可以使用如下的方式使 Π_{dp} 的通信复杂度与 d 无关：离线阶段， P_0 直接以 $\llbracket \cdot \rrbracket$ -sharing的方式分享 $\gamma_{pq} = \vec{\lambda}_p \odot \vec{\lambda}_q$ ，而不是对每一维分享 $\lambda_{p_i} \lambda_{q_i}$ 。在线阶段，也不是分别重构每一维 $m_{p_i q_i}$ ，而是 m_u ，其中 $u = \vec{p} \odot \vec{q}$ 。同样的思路在恶意安全下的协议通信也可以被优化。

(2) **Secure Comparison**：两个算术值的比较一直是实现高效隐私保护机器学习的重要挑战。给定算术分享值 $\llbracket u \rrbracket, \llbracket v \rrbracket$ ，参与方想要计算 $u < v$ 的值，通常的办法是计算 $a = u - v$ ，然后判断 a 的最高符号位 $msb(a)$ ，SecureML和ABY³采用的是GC或者parallel prefix adders。我们利用一个观察： $sign(a \cdot r) = sign(a) \oplus sign(r)$ ，则可以把对 a 的判断转化为对 ra 与 r 的符号位的判断。

4.2 ML Prediction Functions and Abstractions

- Linear Regression: 模型M有 d -维参数 \vec{w} 和一个偏置 b 。客户端C进行一次查询, 输入为 d -维的 \vec{z} , 计算流程为

$$f_{\text{linr}}((\vec{w}, b), \vec{z}) = \vec{w} \odot \vec{z} + b$$

- SVM Regression: 模型M有 $\{\alpha_j, y_j\}_{j=1}^k$, d -维支持向量 $\{\vec{x}_j\}_{j=1}^k$ 和一个偏置 b 。客户端C进行一次查询, 输入为 d -维的 \vec{z} , 计算流程为

$$f_{\text{svmr}}((\{\alpha_j, y_j, \vec{x}_j\}_{j=1}^k, b), \vec{z}) = \sum_{j=1}^k \alpha_j y_j (\vec{x}_j \odot \vec{z}) + b$$

- Logistic Regression: M和C的输入同Linear Regression, 不同的是M需要提供一个 $t \in [0, 1]$, C得到

$$f_{\text{logr}}((\vec{w}, b, t), \vec{z}) = \text{sign}((\vec{w} \odot \vec{z} + b) - \ln(\frac{t}{1-t}))$$

- SVM Classification: 同SVM Regression, 但是C的输出有些改变

$$f_{\text{svmc}}((\{\alpha_j, y_j, \vec{x}_j\}_{j=1}^k, b), \vec{z}) = \text{sign}(\sum_{j=1}^k \alpha_j y_j (\vec{x}_j \odot \vec{z}) + b)$$

5. IMPLEMENTATION AND BENCHMARKING

本文在从多个维度对算法协议的效率进行了比较: 延迟 (计算各个参与方或者服务器在LAN和WAN下的最大运行时间, 以及在LAN和WAN下的在线计算阶段的throughput)。LAN下3PC的throughput通过每秒计算的AES次数来度量, WAN下throughput通过每秒计算的AND门数量来比较。(只放少量的实验截图)

再看各个输入、输出阶段的实验比较

6. Conclusion

本文提出了在3PC下的恶意方案, 对比ABY3在线性能提升了。并且实现了Fairness安全性。接下来的BLAZE工作也是在本文的基础上的提升。

与李开运合作完成。